

Predizione della Soddisfazione Lavorativa dei Dipendenti

Gruppo di lavoro

- Angelo Gadaleta, 649800, a.gadaleta21@studenti.uniba.it
a.gadaleta21@phd.uniba.it

<https://github.com/AngeloGadaleta/Ing-conoscenza-Employee-Survey>

AA 2023-24

Introduzione

In un momento storico in cui c'è concorrenza, sfruttamento e precarietà nell'ambito lavorativo, il dipendente si accontenta del proprio lavoro vivendo dalle 8 alle 12 ore all'interno delle stesse mura, a tal punto da dover combattere per poter avere un briciolo di tempo per se stessi. La mancanza di tempo per se stessi e di riposo è tale da non permettere un risultato efficiente nel campo lavorativo, e l'accumulo di richieste può portare a stress, scatti d'ira ed emozioni forti. La conseguenza di ciò comporta a non saper rapportarsi con i propri colleghi di lavoro, creando ambienti disfunzionali.

Ad oggi nell'Accordo quadro europeo del 2004, lo stress lavoro-correlato (SLC) viene definito come "una condizione che può essere accompagnata da disturbi o disfunzioni di natura fisica, psicologica o sociale a tal punto che i singoli dipendenti non si sentono in grado di corrispondere alle richieste o alle aspettative date dai propri datori". Data la situazione critica, Italia, il vigente quadro normativo, costituito dal Decreto Legislativo n. 81 del 2008, stabilisce l'obbligo per il datore di lavoro di valutare e gestire il rischio stress lavoro-correlato al pari di tutti gli altri rischi per la salute e sicurezza. E nel 2010 la Commissione consultiva permanente per la salute e la sicurezza sul lavoro ha elaborato le indicazioni necessarie alla valutazione del rischio stress lavoro-correlato individuando un percorso obbligatorio.

OBBIETTIVO: In tal proposito, ho cercato di portare tutti i dati e le ricerche nel progetto d'esame, il quale pone l'obiettivo di costruire dei modelli che possano prevedere la soddisfazione lavorativa dei dipendenti a partire da una serie di caratteristiche come l'equilibrio vita-lavoro, livello di stress, l'ambiente di lavoro, il numero di ore di straordinari e altri feature. Con questi dati si può prendere decisioni aziendali per migliorare il benessere dei dipendenti e migliorare la produzione aziendale, o eventualmente può essere utilizzata come arma a doppio taglio per affondare l'azienda.

Requisiti Funzionali

Per la realizzazione del progetto ho deciso di utilizzare il linguaggio di programmazione Python in quanto offre a disposizione delle librerie utili per realizzare un sistema di apprendimento in modo semplice e intuitivo.

Le librerie utilizzate sono:

bnlearn - pacchetto per la scoperta causale imparando la struttura grafica delle reti bayesian, l'apprendimento dei parametri, l'inferenza e i metodi di campionamento.

matplotlib.pyplot – fornisce degli strumenti per poter visualizzare graficamente vari dati (curve di apprendimento, grafici a barre, grafici a torta)

networkx - visualizza graficamente il grafo (usato per osservare la struttura della rete bayesiana) ma è anche utile per elaborare le principali caratteristiche del grafo.

numpy - consente di lavorare con vettori e matrici in maniera più efficiente e veloce di quanto non si possa fare con le liste e le liste di liste (matrici).

pandas - libreria per la manipolazione di dati in formato sequenziale o tabellare, quali serie temporali o dati di microarray. In questo caso manipola un dataset in formato "csv".

seaborn – una libreria di visualizzazione dei dati per Python che fornisce un'interfaccia ad alto livello per la creazione di grafici statistici attraenti e informativi.

DATASET: <https://www.kaggle.com/datasets/lainguyn123/employee-survey> Nell'analisi del dataset sono stati identificati i dipendenti in base alle nozioni base quali al genere, età, stato civile, e sulle nozioni utili per sviluppare il progetto, quali livello di lavoro (junior, medio, senior), carico, numero di ore.

Le feature sono 23 tutte incentrate sul dipendente:

- **EmpID:** identificatore univoco
- **Gender:** genere [maschio, femmina, altro]
- **Age:** età del dipendente [22, 60]
- **MaritalStatus:** stato civile [single, sposato, divorziato, vedovo]
- **JobLevel:** livello di lavoro [Intern/Fresher, junior, medio, senior, lead]
- **Experience:** numero di anni di esperienza lavorativa acquisita [0, 29]
- **Dept:** dipartimento in cui lavora [IT, HR, finanza, marketing, vendite, legale, operazioni, servizio, clienti]
- **EmpType:** tipo di occupazione [tempo pieno, part-time, contratto]
- **WLB:** valutazione del rapporto tra vita-lavoro [1, 5]
- **WorkEnv:** valutazione dell'ambiente di lavoro [1, 5]
- **PhysicalActivityHours:** numero di ore di attività fisica a settimana [0, 5]
- **Workload:** valutazione del carico di lavoro [1, 5]
- **Stress:** valutazione del livello di stress [1, 5]
- **SleepHours:** numero di ore di sonno per notte [4, 10]
- **CommuteMode:** modo di spostarsi [auto, trasporto pubblico, bicicletta, passeggiata, moto]
- **CommuteDistance:** distanza percorsa durante il tragitto in chilometri [1, 29]
- **NumCompanies:** numero di diverse aziende per cui ha lavorato [0, 12]
- **TeamSize:** dimensioni della squadra di cui fa parte [5, 30]
- **NumReports:** numero di persone segnalate, ma applicabile per i livelli senior e piombo [0, 9]
- **EduLevel:** il più alto livello di istruzione raggiunto [scuola, superiori, laurea triennale, master, PhD]
- **haveOT:** informa sui suoi straordinari [vero/falso]
- **TrainingHoursPerYear:** numero di ore di formazione ricevute all'anno [10, 64.5]
- **JobSatisfaction:** valutazione della soddisfazione lavorativa [1, 5]

Sommario

Paragrafo sul KBS e su come integri moduli che dimostrino competenze sui diversi argomenti (specificati sotto)

Elenco argomenti di interesse

- **Paragrafo su argomento 1** : Apprendimento supervisionato, modelli base e modelli composti)
- **Paragrafo su argomento 2** : Apprendimento e incertezza, apprendimento non supervisionato)
- **Paragrafo su argomento 3** : Apprendimento e incertezza, apprendimento di Belief Network)

Apprendimento Supervisionato

Il modello, prendendo in considerazione l'input e dal target dello stress preso dal dataset, analizza l'intensità dello stimolo dato, grazie a utilizzi di esempi di stress su lavoro, identificandolo in un minimo di punteggio 1 e un massimo punteggio di 5. Esempio nel caso in cui un dipendente avesse un quantità di sonno inferiore alla media consigliata, questo comporterebbe a un punteggio massimo di stress, quindi un livello alto d'intensità.

Il progetto è stato sviluppato inizialmente utilizzando la metrica K Fold Crossing Validation, la quale si rende valida nel momento in cui il modello non va in sovradattamento, e quindi non avvenga il overfitting. Dopo ciò, viene utilizzato l'apprendimento supervisionato su quattro modelli: albero di decisione, regressione logistica, random forest e rete neurale. Inseguito vengono impegnate le metriche accuratezza, precision, recall, f1 score, le quali mi identificano quale tra i modelli sia il migliore. Infine viene aggiunta la ROC finale che specifica quali esempi sono veri positivi, falsi positivi, veri negativi e falsi negativi.

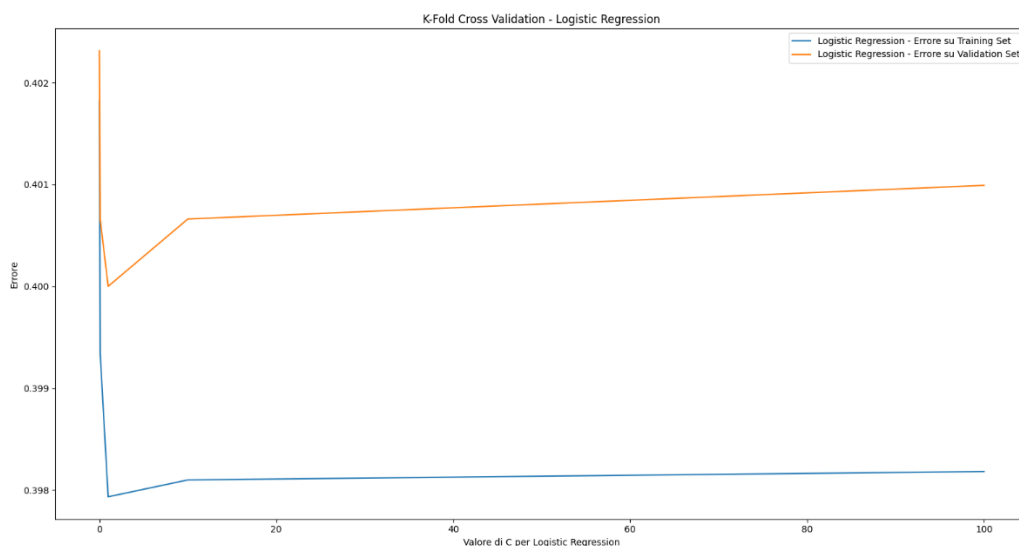
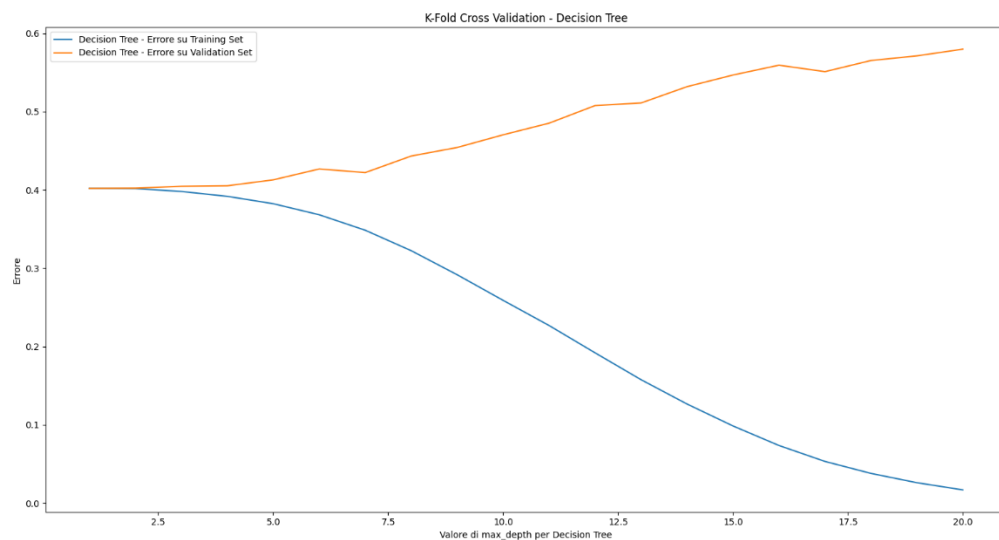
I modelli di apprendimento supervisionato (o anche detti automatico) sono:


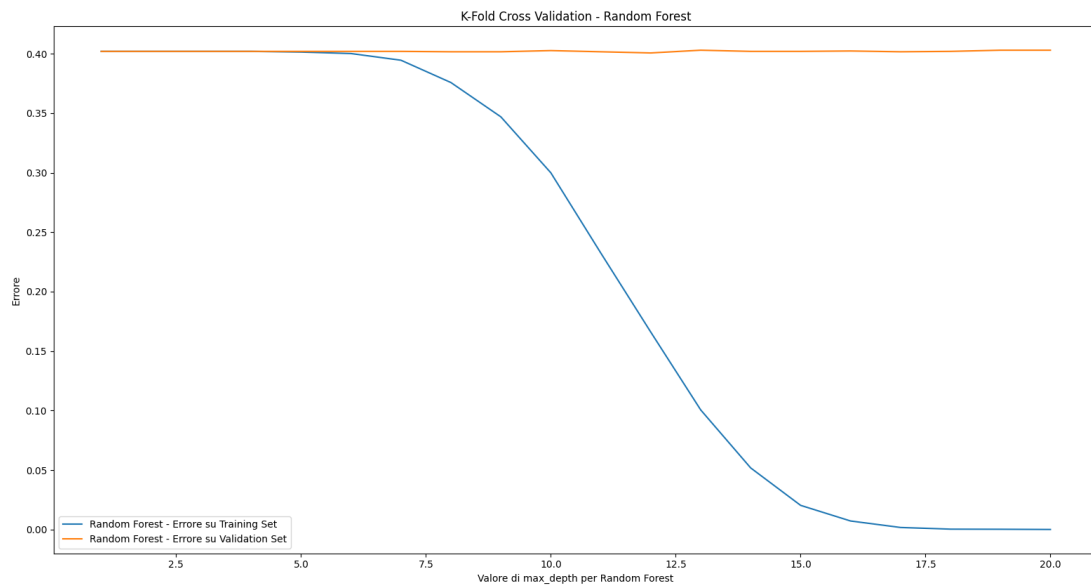
- **Albero di decisione:** Classificatore strutturato ad albero in cui la radice e i nodi interno rappresentano delle condizioni sulle feature di input, mentre le foglie descrivono le classi di appartenenza o le probabilità di appartenenza a tali classi. Seguendo il percorso passando tra le condizioni, si arriverà alla classe di appartenenza.
- **Regressione logistica:** Classificatore simile alla regressione lineare ma viene utilizzata per calcolare le probabilità di appartenenza di un esempio a ogni classe. Per ogni classe si ha una funzione lineare di cui apprende i pesi mediante la tecnica della discesa di gradiente. In essa è presente un peso per ogni feature più un termine noto w_0 . Il risultato viene "schiacciato" da una funzione nota come softmax, la quale trasforma un vettore di valori reali in una distribuzione di probabilità su più classi.
- **Random Forest:** Classificatore composto che si ottiene creando tanti alberi di decisione. Il valore di output si ottiene mediando sulle predizioni di ogni albero appartenente alla foresta, detta anche tecnica di bagging. Esso si pone come soluzione che minimizza l'overfitting del training set rispetto agli alberi di decisione.
- **Rete neurale:** Classificatore composto che si ottiene implementando una funzione di predizione dati le feature di input $F(x) = F_n(F_{n-1}(...(F_2(F_1(X)))...))$ dove ogni funzione F_i mappa un vettore di valori in un vettore di valori e dove F_i è lo strato i -esimo. Il numero di funzioni composte n , è la profondità della rete neurale. L'ultimo strato F_n è lo strato di output. Gli altri strati sono chiamati strati nascosti mentre l'input X è chiamato strato di input. A differenza degli altri modelli, qui si conosce l'input e l'output ma non si conosce lo strato intermedio o nascosto.

Per prima cosa si sono scelti gli iper-parametri da inserire, i quali sono i parametri di un modello di apprendimento supervisionato nel quale non vengono appresi durante la fase di addestramento come i normali parametri del modello, ma devono essere necessariamente fissati prima che il modello possa cominciare l'addestramento. Ogni modello di classificazione prevede la presenza di parametri opportunamente passati in fase di costruzione di un determinato modello. Se non esplicitati, ai parametri verranno associati valori di default, che molto spesso non permettono al modello di esaltare la sua massima accuratezza.

Mentre un iper-parametro viene calcolato utilizzando la tecnica di K-fold Cross Validation (CV). La sua funzione è quella di prendere un dataset, dividerlo in k fold, dove l'insieme delle k sono disgiunti, e il modello viene addestrato k volte. Per ogni iterazione 1 fold viene usato il testing mentre gli altri k-1 fold vengono utilizzati per il training. La K-fold cross validation viene applicato prima della fase di testing vero e proprio per verificare che il modello addestrato sui dati di training sia ottimale. In questo caso per ricercare gli iper-parametri dei modelli si è utilizzato il GridSearch con CrossValidation nel quale vengono specificate le griglie dei valori per gli iper-parametri e si cerca tutte le combinazioni possibili nella ricerca della miglior combinazione possibile.

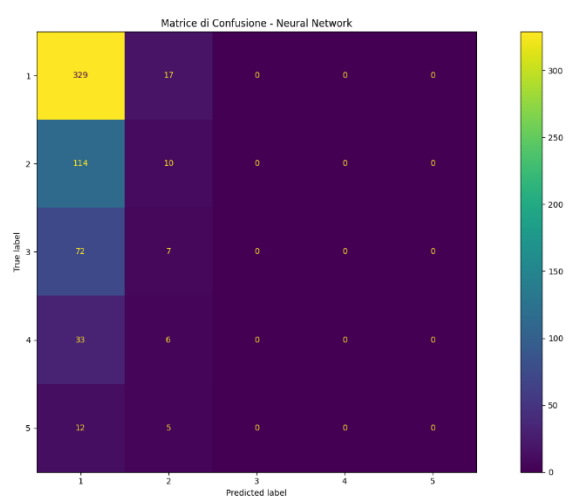



Curve di validazione per ogni modello: albero di decisione, regressione lineare, random forest, rete neurale.






Attraverso questi grafici si può notare come avviene tale procedimento e sulla base di quale metrica si stabilisce il giusto settaggio per un iper-parametro.

Viene effettuata la matrice di confusione che è una tabella in cui le righe rappresentano le etichette vere e le colonne le etichette previste. I valori all'interno della matrice indicano il numero di osservazioni per ciascuna combinazione di valori vero-predetto, come in questo caso. Nel caso di valori binari, la matrice di confusione viene strutturata solitamente con true positive, true negative, false positive e false negative.



Alla fine si è voluto valutare i modelli mettendoli a confronto tra loro per capire quale algoritmo riesce meglio ad apprendere passandogli il dataset.



Si osserva che la regressione logica e la random forest siano migliori nell'accuratezza, mentre la precision, recall e f1-score sia migliore albero di decisione, anche se in certi casi il random forest o la rete neurale risultano migliori come modello. Tuttavia, ci sono diverse ragioni per cui un modello semplice come la regressione logica potrebbe funzionare meglio in alcune situazioni specifiche: overfitting, semplicità dei dati, ottimizzazione dei parametri, interpretabilità, rumore dei dati, capacità di gestire variabili reali e discrete/categoriche.

Apprendimento non supervisionato


L'apprendimento non supervisionato è una branca d'apprendimento nel quale si richiede di imparare a riconoscere schemi nell'input senza alcuna indicazione specifica dei valori in uscita.

Clustering: L'obiettivo è raggruppare gli elementi del dataset in base a delle similitudini.

Nel mio caso, l'apprendimento non supervisionato è stato utilizzato nel raggruppamento delle classi generali che descrivono il dipendente, quali, il genere, età, occupazione, quantità di lavoro da svolgere ecc.

Nel mio caso ho deciso di utilizzare l'algoritmo di hard clustering KMeans e soft clustering EM. Il KMeans ha come problema principale trovare il numero ideale di cluster da fornire in input all'algoritmo. Per risolvere questo problema ho seguito un metodo definito come "curva del gomito".

Applicando l'Elbow Method, "Metodo del Gomito", ho scoperto il numero di cluster più adatto per il dataset. Esso è stato scelto poiché è un modo totalmente oggettivo per determinare il numero di cluster. Esso mostra la somma delle distanze quadrate tra ogni punto dati e il centro del cluster assegnato al variare del numero di cluster, rilevando il punto in cui la diminuzione del calcolo diventa meno significativa.



Nel mio caso possiamo vedere come il numero ottimale di cluster è $k = 3$, dunque successivamente è stato eseguito l'algoritmo K-Means con 3 cluster.

Poi ho fatto stampare l'insieme dei valori delle feature del centroide di ogni cluster in K-means, nel quale ogni valore numerico corrisponde a un valore in stringa, precedente modificato:


```
Centroidi di K-means (valori delle feature per ogni centroide):  
Cluster 1 - Elemento più vicino al centroide: Indice 2174, Valori: [1, 48, 1, 4, 22, 2, 1, 3, 4, 1.5, 5, 2, 6.9, 1, 21, 8, 18, 4, 2, False, 51.0, 4]  
Cluster 2 - Elemento più vicino al centroide: Indice 909, Valori: [1, 22, 2, 1, 0, 5, 1, 4, 3, 2.4, 3, 1, 6.6, 3, 19, 0, 10, 0, 0, False, 20.0, 3]  
Cluster 3 - Elemento più vicino al centroide: Indice 2240, Valori: [1, 36, 1, 4, 14, 6, 1, 4, 2, 2.4, 3, 2, 7.1, 1, 16, 4, 23, 2, 0, False, 47.0, 4]
```

Il soft clustering, invece, è un algoritmo per apprendere modelli probabilistici con variabili latenti:

- problemi di *soft clustering* risolti combinandolo con un classificatore NB,

- analogo a k-Means, ma esempi assegnati ai cluster probabilisticamente stessi argomenti in input: esempi e numero di cluster k.

Alla fine ho fatto stampare la distribuzione dei cluster sui due modelli.




Ogni cluster viene identificato con un indice e con l'indice corrispondente nel dataset. Come possiamo vedere in entrambi i modelli la distribuzione dell'indagine sui dipendenti nei vari cluster non è perfettamente bilanciata, questo perché dipende da come è stato costruito ogni cluster.

Apprendimento Bayesiano o Belief Network

Sommario

Una rete Bayesiana, o Belief Network, è un modello grafico probabilistico. Considerata una variabile X , solamente alcune altre variabili influenzano in maniera diretta il suo valore; ciò significa che X è condizionatamente indipendente dalle variabili restanti. Le variabili che influenzano direttamente X sono dette *parents*(X). Una rete bayesiana dunque utilizza l'ordinamento delle variabili fornito dall'indipendenza condizionata per costruire un grafo orientato aciclico (*Directed Acyclic Graph*). Per adattare una rete bayesiana a un particolare dominio e per fare inferenza su di essa è necessario definire:

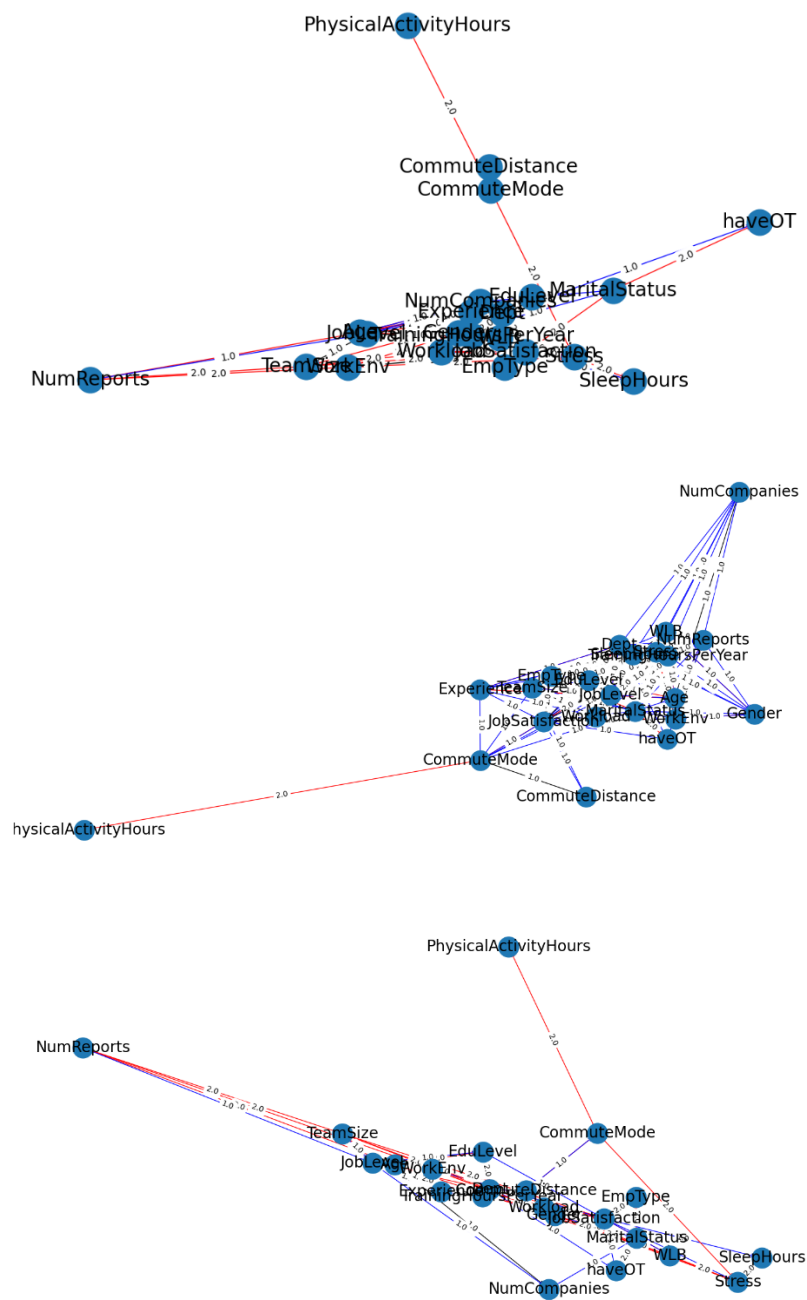
- **Variabili rilevanti**, ogni feature osservata è una variabile rilevante. Nel mio progetto, tutte le 23 feature sono state considerate variabili rilevanti;
- **Relazioni tra le variabili**: tra le variabili: la probabilità che assumono i valori di stress, yes e no, è influenzata direttamente da ('WLB', 'Stress'), ('WorkEnv', 'Stress'), ('Workload', 'Stress'), ('CommuteMode', 'Stress'). Di seguito il grafo completo delle relazioni, formalizzato in seguito all'osservazione dei dati:



Ho deciso di fornire una struttura arbitraria alla rete bayesiana cercando di individuare le possibili dipendenze tra le feature sfruttando le possibili relazioni che possono influenzare una feature rispetto ad un'altra come per esempio lo stress può essere causato da un carico alto di lavoro.

La struttura illustrata in seguito confrontata con tre strutture apprese tramite *HillClimb search*, un approccio di ricerca euristica utile quando sono coinvolti molti nodi, e tre funzioni di score, *BIC*, *K2* e *BDeu*. HillClimb search implementa una ricerca greedy locale che, partendo da un DAG disconnesso, manipola iterativamente i singoli archi al fine di massimizzare lo score. La ricerca termina quando

Questi sono i risultati grafici:



Nel momento in cui c'è l'avvio al programma, vengono mostrati in console i valori di *accuracy*, *precision*, *recall*, *F-score* ed *error* del DAG proposto rispetto ai tre modelli appresi con HillClimb search. Nonostante i valori di queste metriche varino leggermente di volta in volta, il DAG realizzato offre complessivamente una buona performance.

Dipendenza della distribuzione di una variabile dai genitori: a ogni variabile è associata una *tabella delle distribuzioni condizionate* (CPT). La funzione `bnlearn.parameter_learning.fit`, prendendo in input il grafo delle relazioni, si occupa dell'apprendimento dei parametri, costruendo di fatto le CPT associate ai nodi del grafo.

Esistono diversi metodi per la costruzione e popolazione delle tabelle di distribuzioni condizionate; per questo progetto è stata scelta la *Maximum Likelihood Estimation*, che consiste nel massimizzare la funzione di verosimiglianza. Le CPT vengono costruite di volta in volta, acquisendo i dati necessari direttamente dal dataset: questo permette di avere tabelle sempre aggiornate, soprattutto nel caso in cui dovessero aggiungersi nuove osservazioni o dati al dataset. Nella rete bayesiana proposta l'algoritmo utilizzato per fare inferenza probabilistica è l'algoritmo di *eliminazione delle variabili*, che rientra nella categoria dell'inferenza **esatta**: le probabilità sono dunque calcolate precisamente.

Il metodo più semplice per fare inferenza esatta è enumerare tutti i mondi coerenti in base all'evidenza disponibile, ma sfruttando la struttura della rete si possono ottenere risultati migliori, ad esempio applicando l'algoritmo VE, in grado di trovare la distribuzione a posteriori di una variabile in una belief network.

Esempio utilizzato:

```
[Prediction]
0: Gender
1: Age
2: MaritalStatus
3: JobLevel
4: Experience
5: Dept
6: EmpType
7: WLB
8: WorkEnv
9: PhysicalActivityHours
10: Workload
11: Stress
12: SleepHours
13: CommuteMode
14: CommuteDistance
15: NumCompanies
16: TeamSize
17: NumReports
18: EduLevel
19: haveOT
20: TrainingHoursPerYear
21: JobSatisfaction
Choose a variable to predict:11
```

2. L'utente sceglie quali sono le feature osservate e i rispettivi valori per esempio predizione sullo stress osservando la valutazione dell'ambiente di lavoro e sull'esperienza lavorativa:

```

0: Gender
1: Age
2: MaritalStatus
3: JobLevel
4: Experience
5: Dept
6: EmpType
7: WLB
8: WorkEnv
9: PhysicalActivityHours
10: Workload
11: Stress
12: SleepHours
13: CommuteMode
14: CommuteDistance
15: NumCompanies
16: TeamSize
17: NumReports
18: EduLevel
19: haveOT
20: TrainingHoursPerYear
21: JobSatisfaction
You already chose [11]
Choose an evidence:8
1: Very low
2: Low
3: Medium
4: High
5: Very high
Choose a work environment rating:3

```

```

Done choosing evidence(s)? y-nn
-----
0: Gender
1: Age
2: MaritalStatus
3: JobLevel
4: Experience
5: Dept
6: EmpType
7: WLB
8: WorkEnv
9: PhysicalActivityHours
10: Workload
11: Stress
12: SleepHours
13: CommuteMode
14: CommuteDistance
15: NumCompanies
16: TeamSize
17: NumReports
18: EduLevel
19: haveOT
20: TrainingHoursPerYear
21: JobSatisfaction
You already chose [11, 8]
Choose an evidence:4
1: [0, 7]
2: [8, 15]
3: [16, 23]
4: [24, 29]
Choose a work experience range:2

```

3. Il sistema restituisce la predizione

```

Done choosing evidence(s)? y-ny
Chosen evidence(s):
{'WorkEnv': 4, 'Experience': 3}
[{'Stress': 1, 'p': 0.5920087284734746}, {'Stress': 2, 'p': 0.18831721293796488}, {'Stress': 3, 'p': 0.12725367581866337}, {'Stress': 4, 'p': 0.06440510037298434}, {'Stress': 5, 'p': 0.028015282396912856}]

```

Conclusioni

Futuri progetti potrebbero essere:

Fare uno studio approfondito sulla stress causato dallo spostamento o dal continuo cambio delle aziende, e individuare delle politiche per riescano a gestire meglio i mezzi pubblici o le strade per lo spostamento dei pendolari in modo sicuro o attuare politiche che aiutino il dipendente a rimanere nell'azienda.

Individuare possibili relazioni tra stress e produttività lavorativa

Se si realizza una app, può essere utilizzata dal datore per capire la situazione dei dipendenti oppure da parte dei dipendenti per capire quando può essere positivo lavorare per quell'azienda.

Fare un'analisi approfondita sullo stress per farla rientrare tra le malattie. Tale analisi potrebbe portare ad avviare o a individuare delle politiche aziendali per evitare che un dipendente arrivi a alti livelli di stress.